Московский авиационный институт (национальный исследовательский университет)

Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №1 по курсу «Информационный поиск»

Студент: М. Ю. Курносов
Преподаватель: А. А. Кухтичев
Группа: М8О-406Б

Дата:
Оценка:
Подпись:

Москва, 2026

Лабораторная работа №1 «Добыча корпуса документов»

Задача: Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;

Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?

Выделить текст.

Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!

Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

Размер примеров «сырых» документов.
Количество документов.
Размер текста, выделенного из «сырых» данных.
Средний размер документа, средний объём текста в документе.

1 Описание

В качестве корпуса документов был выбран сайт reddit.com и ria.ru. Предполагается добыть в качестве корпуса около 1 000 000 статей с этих сайтов. Документы имеют строение html файлов. В тексте содержится обычно 79 тегов meta содержащих метаинформацию о языке текста предназначения контента для конкретных устройств и другое. Разметка содержит: Мета-информацию: теги <meta> Структурную разметку: <article>, <h1> (заголовок), <p> (абзацы), Служебные элементы: <script>, <style>, <link>, <footer> — не несут текстового контента. Семантические теги: <main>, <header>, <section>. И другие. Основной контент страницы который нас интересует находится:
в элементе с классом class="text-neutral-content-strong m-0 font-bold text-18 xs:text-24 mb-xs px-md xs:px-0 xs:mb-md overflow-hidden"
(заголовок статьи);
в элементе с классом class="md text-14-scalable pb-2xs [–emote-size:20px]"
(основной текст);
в элементе с классом class="flex flex-col px-md xs:px-0 gap-md relative"
(комментарии);

Заголовок содержится в атрибуте aria-label, текст придется партить из дочерних элементов элемента с выявленным классом, как и комментарии.

Для поиска по выбранному корпусу подойдут такие поисковики как Google, Яндекс и встроенный поиск на сайте.

Поиск по запросу dota 2 site:reddit.com в поисковом сервисе Google.com нашел примерно 15 100 000 результатов.

РИА Новости публикует карту сайта в robots.txt. Мы использовали sitemap_article_index.xml — индексный файл, который ссылается на вложенные sitemap-файлы со страницами статей.

Алгоритм парсера sitemap:

Скачиваем sitemap_article_index.xml.

Определяем корневой тег:

<sitemapindex> — это индекс, внутри <sitemap><loc> лежат ссылки на другие sitemap-файлы.

<urlset> — это обычная карта, внутри <url><loc> — реальные URL статей.

Обходим дерево BFS-очередью: для индекса кладём вложенные файлы в очередь, для urlset — забираем URL и пишем в файл и MongoDB.

2 Выводы

В результате выполнения лабораторной работы по курсу «Информационный поиск», были закреплены навыки поиска и сбора информации в сети интернет, осознаны такие понятия как документ, корпус документов, приобретены навыки анализа страниц html, улучшено понимание строения таких страниц.

Список литературы

[1] Маннинг, Рагхаван, Шютце *Введение в информационный поиск* — Издательский дом «Вильямс», 2011. Перевод с английского: доктор физ.-мат. наук Д. А. Клюшина — 528 с. (ISBN 978-5-8459-1623-4 (рус.))

[2] ГОСТ Р 7.05-2008 [Электронный ресурс]: ГОСТР7.0.5-2008 СИБИД. Библиографическая ссылка.Общие требования и правила составления (Переиздание) Применяется с 01.01.2009. URL: https://library.istu.edu/content/gost-r-7-0-5-2008.pdf (дата обращения: 19.09.2026).

[3] Сайт Reddit [Электронный ресурс] Официальный сайт URL: https://www.reddit.com/ (дата обращения: 19.09.2026).

[4] Сайт РИА НОВОСТИ [Электронный ресурс] Официальный сайт URL: https://ria.ru (дата обращения: 19.09.2026).