

Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной
математики

Кафедра вычислительной математики и программирования

Лабораторная работа №1 по курсу «Информационный поиск»

Студент: М. Ю. Курносов
Преподаватель: А. А. Кухтичев
Группа: М8О-406Б
Дата:
Оценка:
Подпись:

Москва, 2026

Лабораторная работа №1 «Добыча корпуса документов»

Задача: Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;

Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?

Выделить текст.

Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!

Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

Размер примеров «сырых» документов.

Количество документов.

Размер текста, выделенного из «сырых» данных.

Средний размер документа, средний объём текста в документе.

1 Описание

В качестве корпуса документов был выбран сайт reddit.com и публикации содержащие информацию об игре Defend of the ancient 2, а так же комментарии под данными статьями. Предполагается добыть в качестве корпуса около 1 000 000 статей и комментариев с этого сайта. Документы имеют строение html файлов. В тексте содержится обычно 79 тегов meta содержащих метаинформацию о языке текста предназначения контента для конкретных устройств и другое. Разметка содержит: Метаинформацию: теги <meta> Структурную разметку: <article>, <h1> (заголовок), <p> (абзацы), <div> Служебные элементы: <script>, <style>, <link>, <footer> — не несут текстового контента. Семантические теги: <main>, <header>, <section>. И другие. Основной контент страницы который нас интересует находится:

в элементе с классом class="text-neutral-content-strong m-0 font-bold text-18 xs:text-24 mb-xs px-md xs:px-0 xs:mb-md overflow-hidden"

(заголовок статьи);

в элементе с классом class="md text-14-scalable pb-2xs [-emote-size:20px]"

(основной текст);

в элементе с классом class="flex flex-col px-md xs:px-0 gap-md relative"

(комментарии);

Заголовок содержится в атрибуте aria-label, текст придется парсить из дочерних элементов элемента с выявленным классом, как и комментарии.

Для поиска по выбранному корпусу подойдут такие поисковики как Google, Яндекс и встроенный поиск на сайте.

Поиск по запросу dota 2 site:reddit.com в поисковом сервисе Google.com нашел примерно 15 100 000 результатов.

2 Выводы

В результате выполнения лабораторной работы по курсу «Информационный поиск», были закреплены навыки поиска и сбора информации в сети интернет, осознаны такие понятия как документ, корпус документов, приобретены навыки анализа страниц html, улучшено понимание строения таких страниц.

Список литературы

- [1] Маннинг, Рагхаван, Шютце *Введение в информационный поиск* — Издательский дом «Вильямс», 2011. Перевод с английского: доктор физ.-мат. наук Д. А. Ключина — 528 с. (ISBN 978-5-8459-1623-4 (рус.))
- [2] ГОСТ Р 7.05-2008 [Электронный ресурс]: ГОСТР7.0.5-2008 СИБИД. Библиографическая ссылка. Общие требования и правила составления (Переиздание) Применяется с 01.01.2009. URL: <https://library.istu.edu/content/gost-r-7-0-5-2008.pdf> (дата обращения: 19.09.2026).
- [3] Сайт Reddit [Электронный ресурс] Официальный сайт URL: <https://www.reddit.com/> (дата обращения: 19.09.2026).